

СОДЕРЖАНИЕ

Введение	3
1 ОБЗОР ПРЕДМЕТНОЙ ОБЛАСТИ.....	5
1.1 Определение намерений пользователя.....	5
1.1.1 KNN.....	5
1.1.2 Классификация.....	5
1.2 Методы автоматического машинного обучения	5
1.3 Текстовые аугментации	6
2 ПРОЕКТИРОВАНИЕ	7

ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ

AutoML – автоматическое машинное обучение.

NLP – обработка естественного языка.

NLU – понимание естественного языка.

Введение

В последние годы наблюдается бурный рост интереса к диалоговым системам на основе искусственного интеллекта (чат-ботам, голосовым помощникам и пр.). Так, по данным трендов, интерес к голосовым технологиям AI вырос почти втрое за пять лет¹. Диалоговые системы внедряются в бизнес-процессы и повседневную жизнь, однако создание их интеллектуальной части – модели определения намерения пользователя (intent classification) – остается сложной задачей. Такой модуль является ключевым компонентом системы, позволяя автоматически выявлять цель запроса пользователя, но учет специфики различных доменов серьезно затрудняет разработку универсальной модели. Проектирование и тонкая настройка модели интенгов требуют значительных экспертных усилий в области NLP и ML. Поэтому актуальной представляется автоматизация данного процесса – создание универсальных решений, способных уменьшить долю ручной работы и упростить разработку моделей классификации интенгов. Автоматизированные подходы к машинному обучению (AutoML) обещают значительно сократить объем ручного труда за счет автоматического подбора оптимальных моделей и параметров, что особенно важно для быстро растущей области диалоговых систем.

На сегодняшний день для задачи классификации интенгов накоплен внушительный арсенал методов. Традиционно применяются алгоритмы классического машинного обучения, такие как наивный tf-idf[1], а также подходы на основе k-ближайших соседей и ансамблевые методы (например, градиентный бустинг). С развитием глубокого обучения все более широко используются нейросетевые модели, таких как BERT[2], которые достигают высоких показателей качества на задачах. Параллельно развиваются технологии AutoML, автоматизирующие выбор моделей и настройку гиперпараметров. Тем не менее, несмотря на прогресс отдельных компонентов, целостных универсальных AutoML-фреймворков, специально ориентированных на определение интенгов пользователя, предложено немного. Существующие решения зачастую требуют участия эксперта для каждой новой предметной области, что указывает на необходимость разработать более обобщенный подход.

В связи с этим актуальной является проблема отсутствия универсального, масштабируемого и эффективного AutoML-решения для классификации интенгов, способного автоматически адаптироваться к разным доменам без глубокого участия человека-эксперта.

Цель исследования заключается в разработке такого универсального AutoML-фреймворка, который способен автоматически подбирать оптимальные модели и их конфигурации для классификации интенгов пользователя. Разработанное решение будет протестировано на различных корпусах данных (наборы пользовательских запросов), а его эффективность сопоставлена с результатами ручной настройки моделей, чтобы оценить выигрыш от автоматизации.

Для достижения поставленной цели в работе решены следующие задачи:

1. разработка архитектуры и программной реализации AutoML-фреймворка для классификации интенгов;
2. экспериментальное испытание фреймворка на нескольких корпусах данных, относящихся к различным предметным областям;
3. сравнение результатов, полученных с помощью AutoML-фреймворка, с качеством моделей, настроенных вручную, и анализ эффективности предлагаемого подхода.

Практическая значимость работы состоит в том, что созданный AutoML-фреймворк может быть непосредственно применен при разработке реальных диалоговых систем – чат-ботов, голосовых ассистентов, систем клиентской поддержки – и других NLP-приложений. Использование такого инструмента позволит ускорить внедрение новых сервисов и снизить порог вхождения для разработчиков за счет автоматизации подбора оптимальной модели под конкретный набор интенгов.

Научная новизна исследования определяется интеграцией современных методов автоматизи-

¹<https://www.verloop.io/blog/100-best-chatbot-statistics>

зированного машинного обучения в единой специализированной архитектуре, ориентированной на задачу классификации интенгов. В предлагаемом решении объединяются передовые подходы, включая трансформерные модели и методы обучения с малым количеством примеров, в рамках одного AutoML-фреймворка. Такое сочетание технологий нацелено на достижение высокой точности и устойчивости модели при минимальном ручном вмешательстве, что ранее не было реализовано в полной мере для задачи определения интенгов пользователя.

1 ОБЗОР ПРЕДМЕТНОЙ ОБЛАСТИ

1.1 Определение намерений пользователя

Классификация намерений – это задача сопоставления высказывания пользователя с предопределенной меткой намерения (семантической категорией цели пользователя). Например, запрос “Какая погода будет завтра?” может быть классифицирован как запрос погоды. Эта способность является ключевым компонентом понимания естественного языка (NLU) в диалоговых системах, позволяя чат-ботам, виртуальным помощникам и другим агентам искусственного интеллекта понимать, чего хочет пользователь, и соответствующим образом реагировать. Классификация намерений уходит корнями в ранние разговорные диалоговые системы (например, телефонное обслуживание клиентов) и с тех пор получила повсеместное распространение в самых разных областях - от личных помощников и ботов поддержки клиентов до систем медицинских и юридических консультаций.

Ранние методы были основаны на правилах, которые разрабатывались вручную, или на классическом машинном обучении с добавлением дополнительных функций. Однако с развитием области преобладать стали статистические методы, которые основываются на анализе данных. Сначала они использовали традиционные алгоритмы машинного обучения, а затем — методы глубокого обучения. Также мы наблюдаем расширение сферы применения: от простой классификации с закрытым набором параметров, когда каждый запрос должен относиться к одному из известных намерений, до более сложных сценариев. Например, к многоцелевой классификации, обнаружению намерений с открытым доменом или открытым набором параметров (когда запрос не соответствует ни одному из известных намерений), а также к распознаванию намерений с минимальным количеством попыток или вообще без них с помощью мощных генеративных моделей.

1.1.1 KNN

1. MLKNN Тут будет описание метода [3]
2. DNNC Тут будет описание метода [4]
3. Hierarchical small navigable small worlds Тут будет описание метода [5]

1.1.2 Классификация

1. Бустинг Тут будет описание метода catboost [6; 7]
2. Трансформеры Тут будет описание метода [2; 8; 9]. Peft[10], LoRa[11]

1.2 Методы автоматического машинного обучения

Автоматизированное машинное обучение (AutoML) относится к автоматизации полного процесса применения методов машинного обучения для решения реальных задач. Вместо того чтобы вручную выбирать алгоритмы, настраивать гиперпараметры, разрабатывать архитектуры моделей и создавать признаки, система AutoML автоматически принимает эти решения на основе данных. Мотивация для развития AutoML вытекает из бурного роста применения машинного обучения и стремления «демократизировать» машинное обучение – сделать современные техники доступными даже для неспециалистов. Модели машинного обучения зачастую чувствительны к множеству параметров (тип модели, архитектура, настройки гиперпараметров, предварительная обработка признаков и так далее), и нахождение оптимальной конфигурации часто требует кропотливого перебора даже для экспертов. Эта проблема особенно заметна в глубоком обучении, где выбор правильной архитектуры сети и стратегии обучения может определять конечное качество модели. Цель AutoML – автоматизировать принятие этих решений, позволяя пользователю просто предоставить данные, а система подбирает оптимальную модель. Данный обзор литературы предоставляет академический анализ AutoML с основным упором

на его применение в обработке естественного языка (NLP), а также включает как фундаментальные работы, так и последние разработки. Мы рассмотрим историческую эволюцию и мотивации AutoML, ключевые технические компоненты, ведущие фреймворки и системы, особенности применения AutoML в задачах NLP (например, классификация текстов, маркировка последовательностей, языковое моделирование), сравнительный анализ производительности и существующие бенчмарки, а также новые тенденции и направления исследований (например, интеграция с фундаментальными моделями, обучение с малым количеством примеров, объяснимость моделей). Обзор ссылается на рецензируемые публикации и академические источники.

- LAMA[12]
- AutoGluon[13]
- H2O[14]
- TPOT
- TextBrew[15]

1.3 Текстовые аугментации

- Intent-augmentation [16]
- Few-shot detection [17]
- Dspy [18]

2 ПРОЕКТИРОВАНИЕ

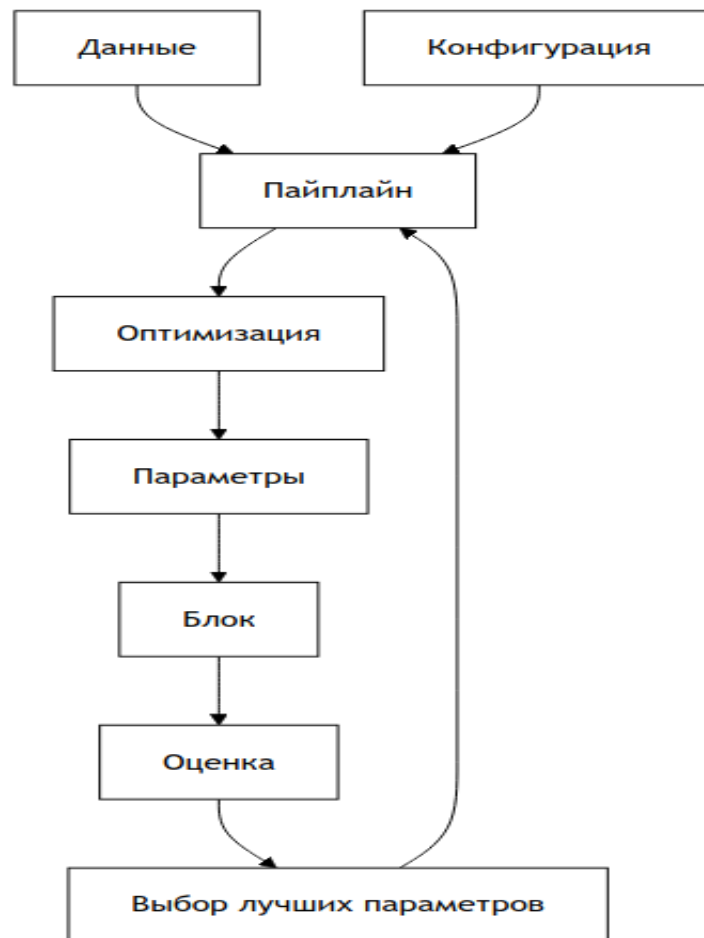


Схема фреймворка

Заклучение

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. *Jones, Karen Sparck*. A Statistical Interpretation of Term Specificity and Its Application in Retrieval // Journal of Documentation. — 1972. — 1 янв. — Т. 28, № 1. — С. 11—21. — ISSN 0022-0418. — DOI: 10.1108/eb026526. — URL: <https://doi.org/10.1108/eb026526>.
2. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding / J. Devlin [и др.]. — 24.05.2019. — DOI: 10.48550/arXiv.1810.04805. — arXiv: 1810.04805 [cs]. — URL: <http://arxiv.org/abs/1810.04805> (дата обр. 02.08.2023). — Пред. пуб.
3. *Zhang M.-L., Zhou Z.-H.* ML-KNN: A Lazy Learning Approach to Multi-Label Learning // Pattern Recognition. — 2007. — 1 июля. — Т. 40, № 7. — С. 2038—2048. — ISSN 0031-3203. — DOI: 10.1016/j.patcog.2006.12.019. — URL: <https://www.sciencedirect.com/science/article/pii/S0031320307000027> (дата обр. 04.04.2025).
4. Discriminative Nearest Neighbor Few-Shot Intent Detection by Transferring Natural Language Inference / J.-G. Zhang [и др.]. — 25.10.2020. — DOI: 10.48550/arXiv.2010.13009. — arXiv: 2010.13009 [cs]. — URL: <http://arxiv.org/abs/2010.13009> (дата обр. 04.04.2025). — Пред. пуб.
5. *Malkov Y. A., Yashunin D. A.* Efficient and Robust Approximate Nearest Neighbor Search Using Hierarchical Navigable Small World Graphs. — 14.08.2018. — DOI: 10.48550/arXiv.1603.09320. — arXiv: 1603.09320 [cs]. — URL: <http://arxiv.org/abs/1603.09320> (дата обр. 04.04.2025). — Пред. пуб.
6. *Dorogush A. V., Ershov V., Gulin A.* CatBoost: Gradient Boosting with Categorical Features Support. — 24.10.2018. — URL: <http://arxiv.org/abs/1810.11363> (дата обр. 28.05.2023).
7. CatBoost: Unbiased Boosting with Categorical Features / L. Prokhorenkova [и др.] // Advances in Neural Information Processing Systems. Т. 31 / под ред. S. Bengio [и др.]. — Curran Associates, Inc., 2018. — URL: https://proceedings.neurips.cc/paper_files/paper/2018/file/14491b756b3a51daac41c2a1Paper.pdf.
8. *Reimers N., Gurevych I.* Sentence-BERT: Sentence Embeddings Using Siamese BERT-Networks. — 27.08.2019. — URL: <http://arxiv.org/abs/1908.10084> (дата обр. 20.12.2022).
9. Attention Is All You Need / A. Vaswani [и др.] // Advances in Neural Information Processing Systems. Т. 30. — 2017. — URL: <https://papers.nips.cc/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html> (дата обр. 28.02.2023).
10. Parameter-Efficient Fine-Tuning for Large Models: A Comprehensive Survey / Z. Han [и др.]. — 29.04.2024. — DOI: 10.48550/arXiv.2403.14608. — arXiv: 2403.14608 [cs]. — URL: <http://arxiv.org/abs/2403.14608> (дата обр. 13.05.2024). — Пред. пуб.
11. LoRA: Low-Rank Adaptation of Large Language Models / E. J. Hu [и др.]. — 16.10.2021. — DOI: 10.48550/arXiv.2106.09685. — arXiv: 2106.09685 [cs]. — URL: <http://arxiv.org/abs/2106.09685> (дата обр. 22.11.2023). — Пред. пуб.
12. LightAutoML: AutoML Solution for a Large Financial Services Ecosystem / A. Vakhrushev [и др.]. — 05.04.2022. — DOI: 10.48550/arXiv.2109.01528. — arXiv: 2109.01528 [cs]. — URL: <http://arxiv.org/abs/2109.01528> (дата обр. 04.04.2025). — Пред. пуб.
13. AutoGluon-Tabular: Robust and Accurate AutoML for Structured Data / N. Erickson [и др.]. — 13.03.2020. — DOI: 10.48550/arXiv.2003.06505. — arXiv: 2003.06505 [stat]. — URL: <http://arxiv.org/abs/2003.06505> (дата обр. 04.04.2025). — Пред. пуб.
14. *LeDell E., Poirier S.* H2O AutoML: Scalable Automatic Machine Learning. — 2020.

15. TextBrew: Automated Model Selection and Hyperparameter Optimization for Text Classification / R. Desai [и др.] // International Journal of Advanced Computer Science and Applications. — 2022. — 1 янв. — Т. 13. — DOI: 10.14569/IJACSA.2022.0130988.
16. *Hu R., Khosmood F., Edalat A.* Exploring Description-Augmented Dataless Intent Classification. — 25.07.2024. — DOI: 10.48550/arXiv.2407.17862. — arXiv: 2407.17862 [cs]. — URL: <http://arxiv.org/abs/2407.17862> (дата обр. 04.04.2025). — Пред. пуб.
17. Few-Shot Learning for Multi-label Intent Detection / Y. Hou [и др.] // Proceedings of the AAAI Conference on Artificial Intelligence. — 2021. — 18 мая. — Т. 35, вып. 14, № 14. — С. 13036—13044. — ISSN 2374-3468. — DOI: 10.1609/aaai.v35i14.17541. — URL: <https://ojs.aaai.org/index.php/AAAI/article/view/17541> (дата обр. 04.04.2025).
18. DSPy: Compiling Declarative Language Model Calls into Self-Improving Pipelines / O. Khattab [и др.]. — 05.10.2023. — DOI: 10.48550/arXiv.2310.03714. — arXiv: 2310.03714 [cs]. — URL: <http://arxiv.org/abs/2310.03714> (дата обр. 04.04.2025). — Пред. пуб.